

两种 Unprocessing 路线对比

共同点：都把 RGB/sRGB 转成 4-channel packed Bayer RAW-like；差异在反推 ISP 假设、随机化语义与实验可比性。

A. 当前训练：sensor_linear_dual

Brooks-style 在线合成；VKITTI2Raw 在 dataloader 中生成 raw4



- 正式配置：raw4 / raw tensor / halfres packed Bayer
- 训练 randomize=True；KITTI eval 用同一 preset 的 deterministic 版本
- sensor_linear_dual 在 ETH3D 与 RobotCar 子 preset 间采样；CFA 可变

当前方法的含义

把 RGB 合成为“多相机统计驱动”的 pseudo-RAW，适合在线训练增强；但它不是 RAW-Adapter 论文口径的 InvISP。

B. 0524 计划：InvISP / RAW-Adapter-style

参考 RAW-Adapter：RGB -> InvISP raw-RGB -> inverse WB -> mosaic



- 0524 脚本是离线 NumPy/PIL 工具：保存 npz/json/preview
- 严格路线依赖外部 InvISP raw-RGB；可运行路线使用 analytic 近似
- normal/dark/over 是显式 variant policy，不混用旧 preset 的曝光 / 噪声范围

InvISP 方法的含义

把 RGB 先投影到 raw-RGB，再做 inverse WB 与 RGGb mosaic；更贴近 RAW-Adapter 描述，但必须作为新方法显式接入。

结论 / 下一步

两者输出接口可以统一为 raw4，但实验语义不能混用。正式比较时应新增 unprocessing_method 分支，并在训练与 KITTI eval 配置中显式保存 backend、CFA、gain、variant/noise policy。

为什么从 RAM→3ch→DAV2 转向 Residual Correction

旧路线是 input replacement：让 RAW-like/RAM 输出伪装成 RGB 进入 DAV2；新路线是 output correction：保留 RGB-DAV2 主先验，只在失败区域做受控修正。

旧路线：把 RAM 输出当成 DAV2 输入

raw4 -> base_rgb -> RamCore3 -> x3 -> frozen DAV2 -> depth

raw4
packed
Bayer

RAM
learned
3ch x3

DAV2
expects
RGB stats

Depth
full map
rewritten

- 输入分布失配：DAV2 是 RGB depth foundation model，x3/RAM 输出不是自然 RGB
- 会重写 DAV2 依赖的语义 - 几何映射：shading、texture、sky/far priors、layout
- RAM 的成功证据主要来自 detection；dense depth 对整图一致性和边界更敏感
- synthetic RAW-like 由 sRGB 反推，不能当成真实新增 sensor information

旧路线的问题定位

不是 RAM 一定无效，而是它把辅助表征放在 DAV2 前面，导致基础模型必须在非 RGB 统计上重新解释整张图。

当前路线：保留 DAV2，只预测修正量

RGB -> frozen DAV2 -> D0；RAW/RAM 特征只进入 gate + delta head

RGB
original
image

DAV2
frozen
main path

D0
base depth
prior

raw4
packed
Bayer

RAM
x3 /
ffm_mid

Head
gate +
delta

Final
D0 +
g*delta

- RGB 仍走 frozen DAV2：保住强 prior，避免破坏输入统计
- RAW-like/RAM branch 只回答 where to fix 与 how much to fix
- zero-init delta、gate bias<0、gate/residual regularization 让初始行为接近 D0
- 更容易证明：RAW-like 是 complementary residual cue，而不是主输入替代物

新路线的关键分工


DAV2 负责整图形状和语义先验；RAW-like/RAM 特征只作为局部误差校正信号，最终 $\text{pred} = \text{D0_norm} + \text{gate} * \text{delta}$ 。

一句话叙事

从“让 RAW-like 替代 RGB 进入 DAV2”，改为“让 RAW-like 在不破坏 DAV2 RGB prior 的前提下修正 DAV2 的 failure regions”。

当前网络训练流程： RGB D0 prior + RAW/RAM residual correction

同一个样本同时走 RGB 主路、 RAW 分支和 GT target 分支； DAV2 frozen/no_grad ，训练 RAM + ResidualGateHead ，最终只学习对 D0_norm 的 $\text{gate} * \text{delta}$ 修正。



三组对照的 head_input 差异

M2 = concat(D0_norm, ffm_mid) ; M1 = concat(D0_norm, x3) ; M3 = concat(D0_norm, x3, ffm_mid) 。 C1 = concat(D0_norm, RGB) , C2 = D0_norm only 。

Loss 设计：让 residual 改该改的地方，不破坏 D0 prior

target 在 normalized inverse-depth 空间； gate 的监督来自 D0 与 GT 的误差分布，所以训练目标天然是在 D0 failure regions 做受控 correction。

Target

$y_{\text{norm}} = \text{robust_normalize}(1 / \text{depth}, \text{valid_mask})$

D0 error mask

$e0 = |D0_{\text{norm}} - y_{\text{norm}}|$; $m_error = \text{q80} \rightarrow \text{q95}$ soft mask

Correction

$\text{gate_delta} = \text{gate} * \text{delta}$; $\text{pred} = D0_{\text{norm}} + \text{gate_delta}$

L_depth weight=1.0

$\text{mean} | \text{pred} - y_{\text{norm}} | \text{ over valid pixels}$

主监督：让最终预测接近 GT target。

L_grad weight=0.5

$\text{gradient_l1}(\text{pred}, y_{\text{norm}})$

约束局部斜率和边界，减少只对齐均值但形状错误。

L_keep weight=0.1

$\text{mean}((1 - m_error) * | \text{gate_delta} |)$

D0 已经好的区域，惩罚 residual 乱改。

L_res weight=0.01

$\text{mean} | \text{gate_delta} |$

限制最终 correction 幅度，让模型保守地修正。

L_gate weight=0.005

mean gate

让 gate 不要整图打开，保持 correction 稀疏。

L_gate_sup weight=0.05

$\text{BCE}(\text{gate}, m_error)$

用 D0 high-error mask 指导 gate：错得多的地方更该开。

完整目标



$\text{loss} = L_{\text{depth}} + 0.5 * L_{\text{grad}} + 0.1 * L_{\text{keep}} + 0.01 * L_{\text{res}} + 0.005 * L_{\text{gate}} + 0.05 * L_{\text{gate_sup}}$

直观理解

$L_{\text{depth}}/L_{\text{grad}}$ 负责把 pred 拉向 GT； $L_{\text{keep}}/L_{\text{res}}/L_{\text{gate}}$ 负责不乱改； $L_{\text{gate_sup}}$ 负责告诉 gate 应该在哪里打开。

M2 raw + D0_norm 具体网络结构

这一页展开 residual_feature_source=ffm_mid 的路径：RAW/RAM 负责产生 64ch feature，D0_norm 提供 1ch prior，二者拼成 65ch 后进入 ResidualGateHead。




训练边界

Frozen/no_grad: DAV2 与 D0_norm；Trainable: RamCore3 + ResidualGateHead。当前 M2 使用 [D0_norm, ffm_mid]，不把 x3 再送进 DAV2。


正式实验 control : C1 RGB residual vs C2 D0-only residual

C1/C2 不使用 RAW/RAM , 专门回答 residual gain 来自哪里: RGB appearance 是否有额外帮助, 还是 D0 几何本身已经足够做 post-processing。



C1 : RGB residual control

head_input = concat(D0_norm, image_rgb_norm)



- 测试普通 RGB appearance 是否能在 D0 之外继续提供 residual cue
- trainable params: 2,883,586 ; 只比 C2 多第一层 3 个输入通道
- 风险: appearance shortcut , Scene20 holdout 上 early best 后回退

C2 : D0-only residual control

head_input = D0_norm.unsqueeze(1)



- 测试 D0 自身是否已足够做局部 calibration / post-processing
- trainable params: 2,881,858 ; 只训练 residual head
- 当前最强 control : M 系列必须超过 C2 才能证明 RAW/RAM cue 额外有效

当前 formal 结果速记

VKITTI best abs_rel: C2 0.12100 @11 < C1 0.12574 @03 ; KITTI best abs_rel: C2 0.09503 @06 < C1 0.09843 @06 。 C2 更稳定, 也定义了后续 M-series 的必须超过基线。